

# 인과추론과 실무 : 이질적 처치 효과와 메타 러너

가짜연구소 인과추론팀

발표자 : 이은경

# 1. ATE에서 CATE로


## Overview : ATE에서 CATE로

- 기존의 ATE 는 “전체” 모집단에 대한 처치 효과 관련 정보만 제공해준다

→ 개인 별, 상황 별 처치 효과가 어떻게 다른지에 대한 관심이 증가하면서, ATE보다 더 많은 정보를 주고 싶은 desire 발생

Question) 전체 모집단을 대상으로 수행한 A/B test의 결과는 만족스럽지 않더라도, 특정 user들(subset)의 처치 효과는 strong 할 수 있지 않을까?

전체 모집단에 대해 처치 시행 여부를 결정하는 것보다, “누구”에게 “어떤” 처치를 하는지에 관한(=개인화) 다른 유형의 결정을 할 수 있는 방법은 없을까?



→ 이질적 효과를 고려해 조건부 평균 처치 효과(Conditional Average treatment effect ; CATE), 이질적 처치 효과(Heterogeneous treatment effect ; HTE)를 추정해보자!

# CATE 및 HTE

## • CATE의 정의

- Binary treatment :  $E[Y^1 - Y^0 \mid X]$
- Continuous treatment :  $E[y'(t) \mid X]$ 
  - **treatment effect**를 객체 특성( $X$ )의 함수 형태로 표현한 부분이 핵심!
- $X$ 에 대한 조건부는, 각 실험 대상이 공변량  $X$ 로 정의된 특성에 따라 처치 효과가 다를 수 있음을 의미한다
  - 모든 대상이 처치에 동일하게 반응하지 않는다고 가정

## • HTE의 정의

관점 1) Conditional Average Treatment Effect(CATE)와 동일한 의미

관점 2) CATE 간의 차이 (=Sub-group analysis)

→ 대상의 특성에 따라, 데이터를 계층화 하고, 각 계층 내에서 ATE를 추정(=CATE)하여 계층 간의 차이를 비교

## • Notation 정리

- 결과 변수(Outcome) :  $Y$ 로 표기
- 처치 변수(Treatment) :  $T$ 로 표기
- 공변량(Covariate) :  $X$ 로 표기

## 2. Meta-Learner

# Meta-Learner

- Meta-Learner(메타 러너)의 정의

- 메타 러너는 기존의 예측 Machine-learning(i.e Base-learner) 알고리즘을 활용해, 처치 효과를 추정하는 방법이다.  
(= 일반적인 Supervised learning model을 다양하게 활용하는 알고리즘)

- Uplifting model이라 지칭하기도 한다.

- Meta-Learner(메타 러너)의 종류

- S-learner
- T-learner
- X-learner
- R-learner

Python 내 "CausalML", "EconML" package 통해 사용할 수 있음

→ Binary treatment 상황을 가정



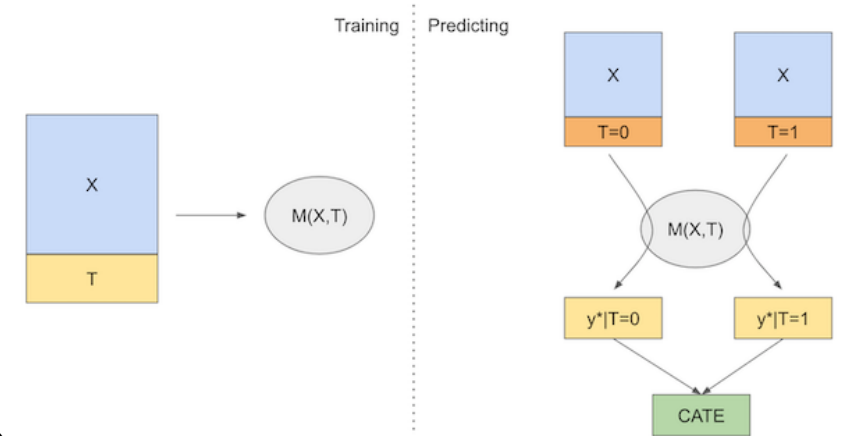
# S-Learner

## • S-Learner

- S-learner는 가장 기본적(simple)인 방식으로, 단일 머신 러닝 모델  $\hat{\mu}$ 를 사용하여 CATE를 추정한다.
- 처치 변수  $T$ 를 공변량  $X$  중 하나로 취급  
→ 결과 변수  $Y$ 를 처치 변수  $T$ 와 공변량  $X$ 의 함수 형태로 표현

$$\text{Base-learner} = \mu(x, t) := E[Y^{obs} \mid X = x, T = t]$$

$$CATE = \hat{t}(x) = \hat{E}[Y^1 - Y^0 \mid X = x] = \hat{\mu}(x, 1) - \hat{\mu}(x, 0)$$



## • Training

- base-learner의 hyper-parameter tuning은 cross-validation 이용해 진행  
→ base-learner로 Elastic-net regression 혹은  $T$ 와  $X$  간 상호작용 term이 들어간 linear regression model을 많이 사용

## • S-Learner의 장/단점

- 하나의 머신 러닝 모델만 학습하면 된다.
- Treatment group 혹은 control group 중 한 group의 data volume이 적어도, model이 더 많은 양의 data 사용해 일반적인 trend를 학습
- 다른 meta-learner에 비해 해석이 용이
- $Y$ 에 대한 처치의 영향력보다 공변량의 영향력이 더 큰 경우, 처치 효과를 거의 0에 가깝게 추정

→ 추정된 ATE 값이 크거나, data 규모가 적는데, 결과 해석이 중요할 때 좋은 선택지가 될 수 있다.

# T-Learner

## • T-Learner

- T-learner는 잠재적 결과를 추정하기 위해 처치 범주 별, 결과 model  $\mu_t(x)$ 를 적합 한다.
- 처치 변수  $T$ 에 대해 conditioning, 결과 변수  $Y$ 를 공변량  $X$ 의 함수 형태로 표현  
→ Binary treatment 경우, 학습이 필요한 model은 2개 뿐이다. (Two model → T-learner)

$$\left. \begin{aligned} \mu_1(x) &= E[Y^{obs} \mid X = x, T = 1] \\ \mu_0(x) &= E[Y^{obs} \mid X = x, T = 0] \end{aligned} \right\} \text{Base-learner}$$

$$CATE = \hat{\tau}(x) = \hat{E}[Y^1 - Y^0 \mid X = x] = \hat{\mu}_1(x) - \hat{\mu}_0(x)$$

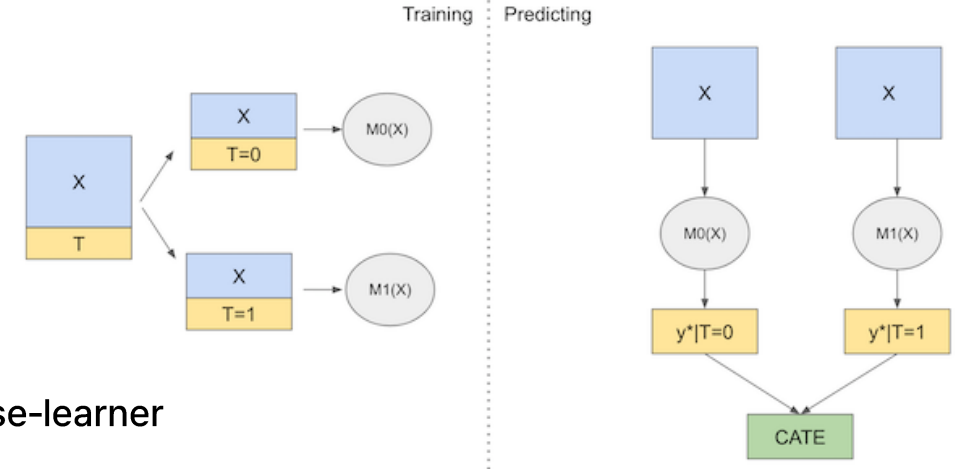
## • Training

- base-learner의 hyper-parameter tuning은 cross-validation 이용해 진행

## • T-Learner의 장/단점

- 추정된 ATE 값이 적어도, CATE 및 HTE 추정에 사용할 수 있다.
- 다른 meta-learner에 비해 해석이 용이
- 처치 범주 별, 모형을 따로 적합하는 형식이므로 각 group의 데이터가 적으면 overfitting 될 가능성이 있다.
- 공변량  $X$ 의 분포가 특정 구간에 몰려 있거나, 혹은 비어 있으면 예측의 정확성이 떨어질 수 있다.  
→ 각 group 별 데이터가 충분한지, 공변량 분포의 균형이 맞춰져 있는지 선 확인 필요

→ S-Learner로 잘 추정되지 않는 small treatment effect 추정할 때 좋은 선택지가 될 수 있다.





# X-Learner

## • X-Learner

- X-learner는 T-learner 기반이며, 서로 반대 group의 정보를 이용해 **counterfactual**를 추정한다.  
→ Binary treatment 경우, treatment group의 counterfactual outcome을 추정하기 위해 control group의 데이터를 이용한다.
- 총 3단계로 나누어 CATE를 추정한다.
  1. 처치 범주 별, response model을 적합 한다. (base learners for the first stage)

$$\mu_1(x) = E[Y^{obs} \mid X = x, T = 1]$$

$$\mu_0(x) = E[Y^{obs} \mid X = x, T = 0]$$

2. Base learner를 이용해 객체 별, treatment effect를 추정한다. (imputed treatment effects)

$$\begin{aligned} \widetilde{D}_i^1 &= Y_i - \widehat{\mu}_0(X_i) \\ \widetilde{D}_i^0 &= \widehat{\mu}_1(X_i) - Y_i \end{aligned} \rightarrow \text{이때, } \widehat{\mu}_0 = \mu_0 \text{ 이고, } \widehat{\mu}_1 = \mu_1 \text{ 이면 } \tau(x) = E[\widetilde{D}^1 \mid X = x] = E[\widetilde{D}^0 \mid X = x] \text{ 일 것이다.}$$

- 2-1.  $\tau_1(x) = E[\widetilde{D}^1 \mid X = x]$ 을 추정하기 위해 treatment group에 대해  $\widetilde{D}^1$ 을 반응 변수로,  $X$ 를 설명 변수로 설정하여 예측 모델을 적합 한다.  
마찬가지로,  $\tau_0(x) = E[\widetilde{D}^0 \mid X = x]$ 을 추정하기 위해 control group에 대해  $\widetilde{D}^0$ 을 반응 변수로,  $X$ 를 설명 변수로 설정하여 예측 모델을 적합 한다.  
(base learners for the second stage)

3. 2-1 기반의 base-learner 이용해 CATE 추정량을 다음과 같이 정의한다.

- $g(x)$ 는 가중치로, 보통 성향 점수를 사용한다.  
→  $g(x)$  설정 시 한 group수가 다른 group에 비해 너무 많거나 혹은 너무 적은 경우, 가중치를 1 / 0 으로 설정하기도 한다.


$$CATE = \hat{\tau}(x) = g(x)\hat{\tau}_0(x) + (1 - g(x))\hat{\tau}_1(x)$$

# Intuition behind the X-Learner

- X-Learner는 counterfactual를 추정하기 위해 반대 group의 정보를 이용한다.

(상황 가정) Treatment group의 수가 Control group에 비해 월등히 적은 상황에서, CATE를 공변량의 함수 형태로 추정하고 싶은 상황이라 가정하자.

- 해당 상황은 online data source에서 많이 찾아볼 수 있다.
- 다음 그림에서 treatment group의 outcome은 원으로, control group의 outcome은 X로 표시하였다. 해당 예제에서 true CATE는 상수 1이라 가정한다.



- 첫 시도로 T-learner 사용

- $\mu_1(x) = E[Y^{obs} | X = x, T = 1]$  추정을 위해 linear model(dashed line)을 사용
- $\mu_0(x) = E[Y^{obs} | X = x, T = 0]$  추정을 위해 piecewise linear function을 사용  
→  $CATE = \hat{\tau}(x) = \hat{E}[Y^1 - Y^0 | X = x] = \hat{\mu}_1(x) - \hat{\mu}_0(x)$  이용해 CATE 추정 ((c) 그림의 solid line)

- 다양한 문제점 발견

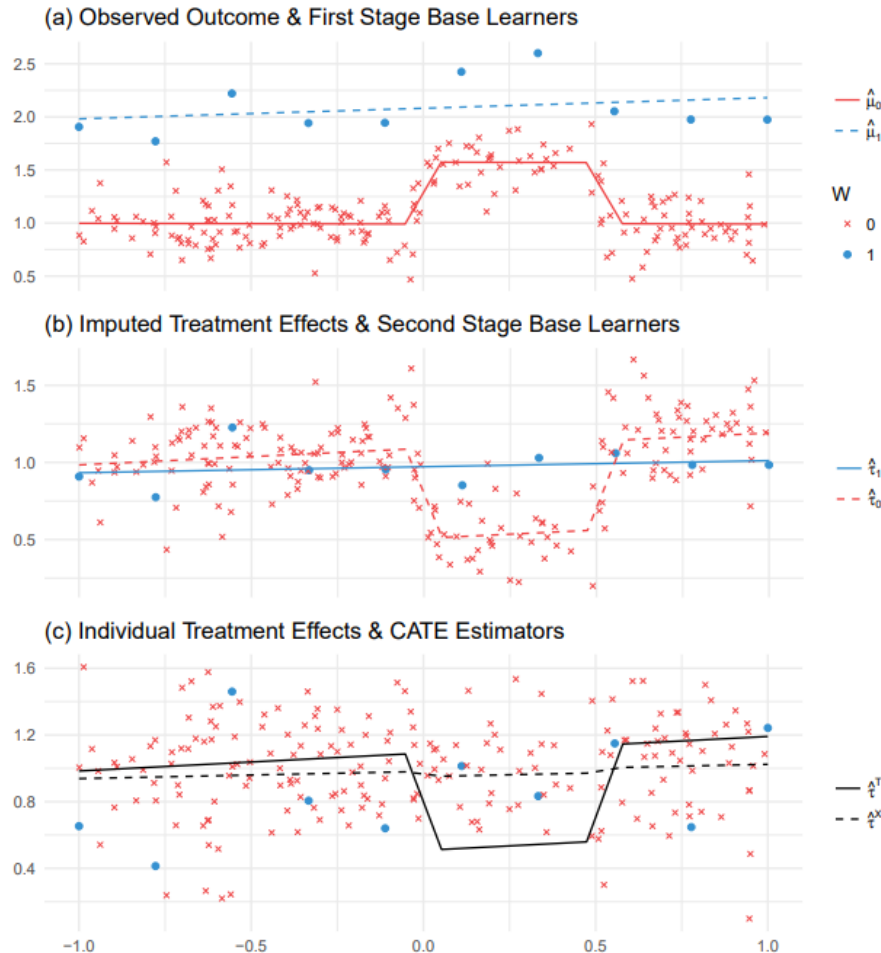
- 1)  $\mu_1(x)$  추정 시 overfitting 문제 발생 가능
- 2) 실제 CATE는 상수인데, 추정치는 상수가 아님을 알 수 있다.  
→ 두 group의 경향을 종합적으로 고려하지 않음을 추측할 수 있다.

→  $\hat{\mu}_1 - \hat{\mu}_0$ 가 CATE의 좋은 추정량이 될 수 있도록 방향을 바꿔야 하지 않을까?

# Intuition behind the X-Learner

(상황 가정) Treatment group의 수가 Control group에 비해 월등히 적은 상황에서, CATE 공변량의 함수 형태로 추정하고 싶은 상황이라 가정하자.

- 다음 그림에서 treatment group의 outcome은 원으로, control group의 outcome은 X로 표시하였다. 해당 예제에서 true CATE는 상수 1이라 가정한다.



- 두 번째 시도로 X-learner 적용
  - base-learner of the first stage는 앞에서 사용한 T-learner의 base-learner와 동일하게 설정
  - $\hat{\mu}_1(x)$ 와  $\hat{\mu}_0(x)$  이용해 각 객체의 treatment effect( $\widetilde{D}_i^1, \widetilde{D}_i^0$ ) 추정 ((b) 그림)
  - $\tau_1(x) = E[\widetilde{D}^1 | X = x, T = 1]$  추정 위해 linear-function을,  $\tau_0(x) = E[\widetilde{D}^0 | X = x, T = 0]$  추정 위해 piecewise-linear function 사용
- $CATE = \hat{\tau}(x) = g(x)\hat{\tau}_0(x) + (1 - g(x))\hat{\tau}_1(x)$  이용해 CATE 추정 ( $g(x)$ 는 성향 점수 사용)
- T-learner 이용한 CATE 추정치와 비교해보았을 때, X-learner 이용한 CATE 추정치가 true CATE에 더 가까움을 알 수 있다.

→ X-learner는 unbalanced design에서의 구조적 정보를 활용한다.

# X-Learner

## • X-Learner

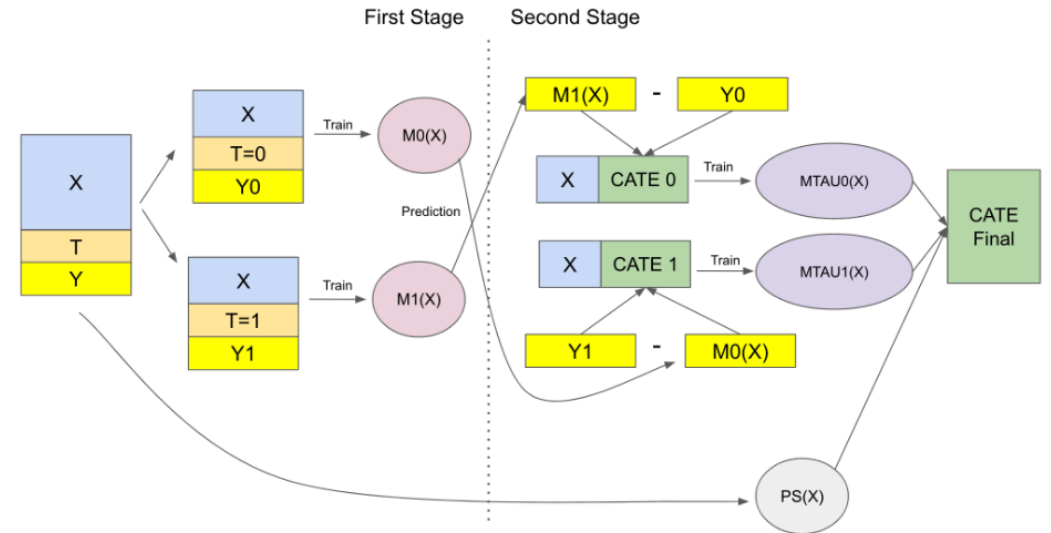
- X-learner는 T-learner 기반이며, 서로 반대 group의 정보를 이용해 counterfactual를 추정한다.

## • Training

- 각 stage 내 base-learner의 hyper-parameter tuning은 cross-validation 이용해 진행

## • X-Learner의 장/단점

- 추정된 ATE 값이 적어도, CATE 및 HTE 추정에 사용할 수 있다.
- Local sparsity에 대해 T-learner보다 robust한 추정치를 제공함
- T-learner 처럼, model이 처치 군 / 대조 군에 대해 각각 학습이 되어 하므로, 각 group내 data volume이 적으면 overfitting 문제가 발생 가능하다.
- X-learner는 multi-stage model이기 때문에, first-stage 내 model 적합으로 부터 오는 내재적 위험이 있다. 따라서, first-stage model의 예측력이 약할 때, X-learner 사용을 조심해야 한다.
- multi-stage model이므로 해석이 용이하지는 않다.



# R-Learner

## • R-Learner

- 이중/편향 제거 머신 러닝이라고 하며, FWL 정리(Frisch-Waugh-Lovell)의 정제된 버전이다.
- FWL 정리 : 회귀 분석 시, 편회귀계수를 구할 때 사용하는 정리 중 하나로, 잔차 및 직교화 개념을 이용한다.
  - 각 변수들의 영향력을 명확히 분리한다.
  - 계산 상의 이점이 있다.

1. 먼저, 다음과 같은 관계식을 설정한다.

$Y_i = \mu_y(X_i) + \tau(X_i)(T_i - \mu_t(X_i)) + \varepsilon_i$  -- (1)  $\rightarrow$  이때,  $\mu_y = E[Y|X]$  이고  $\mu_t = E[T|X]$  이다.  $\tau(X_i)$ 가 추정하고 싶은 CATE이다.

(1)식을 정리하면 다음과 같다.  $\varepsilon_i = (Y_i - \mu_y(X_i) + \tau(X_i)(T_i - \mu_t(X_i)))$  -- (2)

여기서 (2) 식을 "인과 손실 함수" 혹은 "R 손실" 이라 부르며, (2)식의 제곱의 기댓값을 최소화하면  $\tau(X_i)$ 을 추정할 수 있다.

$$\tau(\cdot) = \operatorname{argmin}(E[\{Y_i - \mu_y(X_i)\} - \{T_i - \mu_t(X_i)\}\tau(X_i)]^2)$$

2. 이때,  $\mu_y(X_i)$ 와  $\mu_t(X_i)$  또한 추정이 필요한 부분이다. 이 변동성과 복잡성을 반영하기 위해 (3)과 같은 경험적 손실 함수를 설정한다.

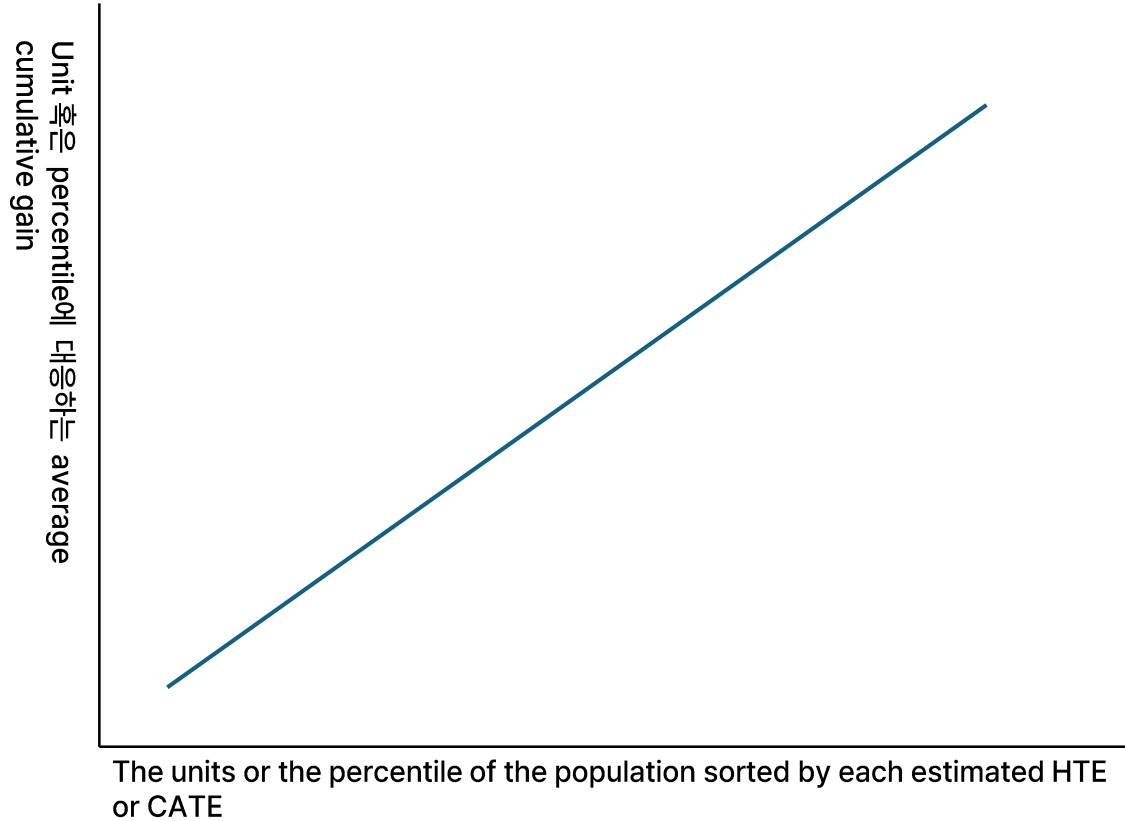
$\tilde{\tau}(\cdot) = \operatorname{argmin}(\frac{1}{n}\sum_{i=1}^n[\{Y_i - \mu_y(X_i)\} - \{T_i - \mu_t(X_i)\}\tau(X_i)]^2 + \Lambda_n\{\tau(\cdot)\}) = \operatorname{argmin}[L_n\{\tau(\cdot)\} + \Lambda_n\{\tau(\cdot)\}]$  -- (3)  $\rightarrow \Lambda_n\{\tau(\cdot)\}$  항목은 regularity term으로 간주한다.

$\hat{\tau}(\cdot) = \operatorname{argmin}[\widehat{L}_n\{\tau(\cdot)\} + \Lambda_n\{\tau(\cdot)\}], \widehat{L}_n\{\tau(\cdot)\} = \frac{1}{n}\sum_{i=1}^n[\{Y_i - \widehat{\mu}_y^{(-i)}(X_i)\} - \{T_i - \widehat{\mu}_t^{(-i)}(X_i)\}\tau(X_i)]^2 \rightarrow \widehat{\mu}^{(-i)}$  항목은 i번째 관측치를 제외하고 적합한 함수를 의미한다.

- k-fold cross validation을 통해 정확성이 가장 높은  $\mu_y, \mu_t$ 를 추정한다.
- $Y_i - \widehat{\mu}_y^{(-i)}(X_i)$ 가 반응 변수이고,  $T_i - \widehat{\mu}_t^{(-i)}(X_i)$ 가 설명 변수인 linear regression with regularization을 적합 한다.

# Metrics for Heterogeneous Effect Estimation

- Uplift Curve (i.e 누적 이득 곡선)



- y축 값 : 
$$\text{Uplift}(b) = \left( \frac{Y_b^1}{N_b^1} - \frac{Y_b^0}{N_b^0} \right) (N_b^1 + N_b^0) - (*)$$
  - 이때,  $Y_b^1$ 은 b번째 units 내 treatment group에 속한 객체들의 sum of outcome을,  $N_b^1$ 은 b번째 units 내 treatment group에 속한 객체들의 수를 의미한다.
  - $Y_b^0$ 은 b번째 units 내 control group에 속한 객체들의 sum of outcome을,  $N_b^0$ 은 b번째 units 내 control group에 속한 객체들의 수를 의미한다.
- Uplift curve(i.e Cumulative gain curve) 아래 면적이 넓을 수록 HTE 추정이 잘 되었다고 판단한다.
  - Uplift coefficient =  $\sum_{b=0}^{N-1} \frac{1}{2} (\text{Uplift}(b+1) + \text{Uplift}(b))$

# 3. Applications

# Using uplift modeling for consumer personalization and targeting

## (Background)

- DoorDash에서는 지속적으로 다르게 행동하는 고객들이 맞춤형 promotion을 받을 수 있도록 HTE model을 활용하고 싶다.
- Positive reaction을 받을 수 있도록 개인에게 적합한 promotion만 송부하여 마케팅 비용 절감을 원한다.

## (Want to know)

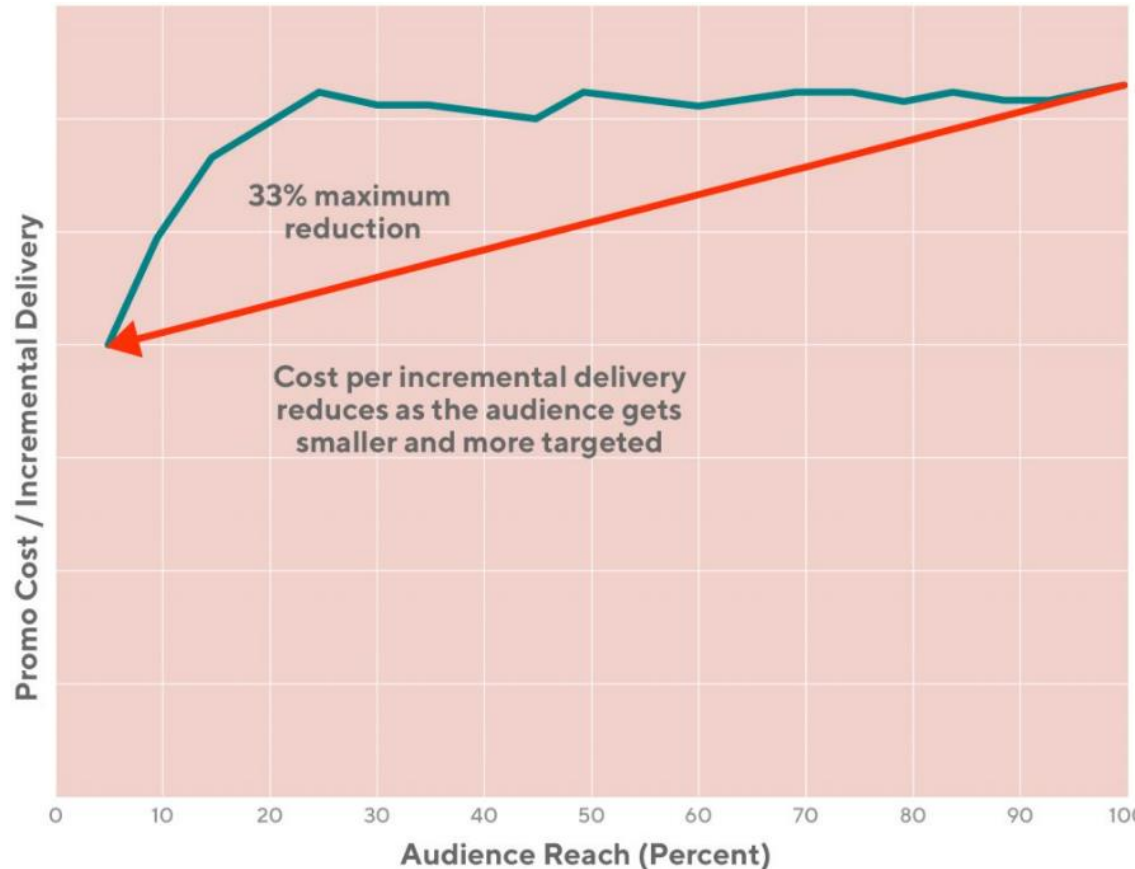
- 소비자들이 promotion을 받고 한달 뒤, 고객의 주문량이 "얼마나" 증가할까?
- 이전 A/B Test에 사용한 data를 활용해 28일 뒤, 고객의 주문량을 예측하는 model을 구축하고자 한다.
- Training data 생성 방안
  - Promotion 진행 후, 실제로 주문을 한 고객의 모든 데이터를 가져온 뒤, "promo\_order"라는 변수를 생성한다. 그리고, 모든 row에 대해 "True" 값을 부여한다.
  - "promo\_order=False" data를 생성하기 위해 "promo\_order=True"인 sample의 공변량 분포가 동일하지만, 주문을 진행하지 않은 소비자의 정보를 가져온다.
- S-learner 적합
  - 사용 가능한 data의 수가 적어, S-learner를 적합
  - base-learner는 LightGBM model 사용
  - 사용한 공변량 : 과거 주문 수, 최근 앱 방문 수, 앱 사용 기간, 리뷰 평점, 이용 가능한 상점 수 등



# Using uplift modeling for consumer personalization and targeting

(Want to know)

- 소비자들이 promotion을 받고 한달 뒤, 고객의 주문량이 "얼마나" 증가할까?
- 이전 A/B Test에 사용한 data를 활용해 28일 뒤, 고객의 주문량을 예측하는 model을 구축하고자 한다.

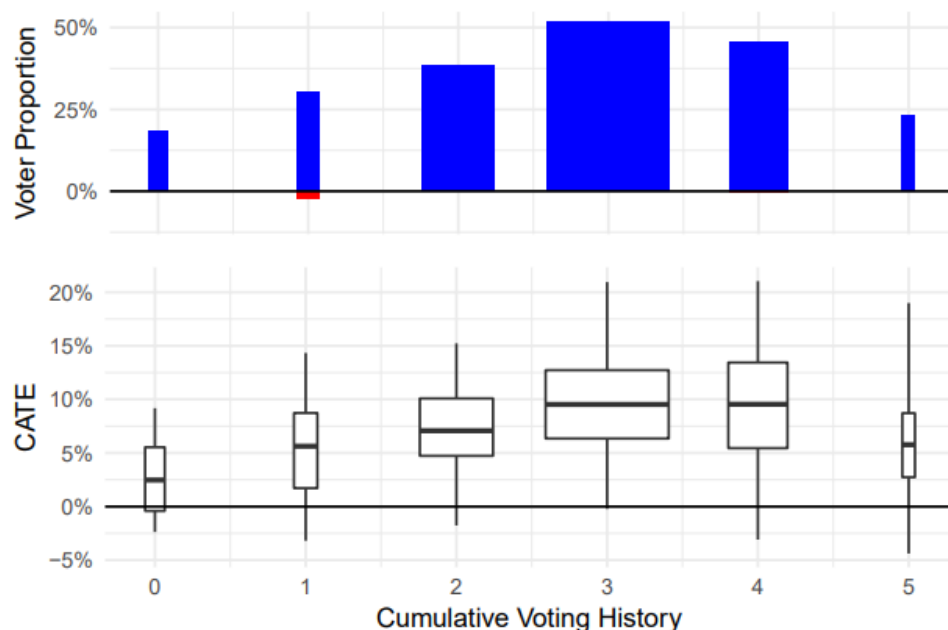


- HTE model 구축을 통해, 진행할 promotion에 더 긍정적으로 반응할 subset을 찾음
- promotion을 원하지 않는 소비자에게 promotion을 전송하는 행위를 방지
- Promotion 비용 / 추구하는 효과 등의 limit을 설정하면, Promotion cost를 절약할 수 있을 것이다.
- 해당 예시에서는 5%의 audience reach를 목표로 설정, promotion cost를 33% 절감시킴

# Social Pressure and voter turnout

(Want to know)

- 사회적 압력이 투표율을 높이는지 알아보기 위한 대규모 투표 실험 (2006년 8월 선거 전, 미시간에서 진행된 실험)
- Study Design
  - Study population : 2004년 선거에 참여한 유권자들
  - Treatment : "DO-YOUR CIVIC DUTY-VOTE!"라는 문구가 담긴 우편물 송부 여부, 처치는 임의 할당
  - Outcome : 2006년 선거 투표 여부
  - 공변량 : gender / age / 2000년, 2002년, 2004년에 행해진 primary 선거 참여 여부 / 2000년, 2002년에 행해진 general 선거 참여 여부



- X-learner를 사용하였으며, base-learner로 모두 random forest를 사용함.
  - 위 panel은 과거 투표 회수 별 population의 비율을, 아래 panel은 각 subset 별 CATE 추정치 및 신뢰구간을 보여준다.
  - 다른 공변량은 고정, 과거 투표 회수 기준으로 conditioning 한 다음, CATE 추정치를 비교해보면 적어도 3번 이상 투표한 유권자들에게 처치를 할당하는 것이 더 효과적이라 생각할 수 있다.
- 각 subset 별 treatment effect 추정치를 가지고 있으면, **targeting** 집단을 선정하는데 유리한 지점이 있다.

## 4. Special Case

# Multiple Treatment Groups

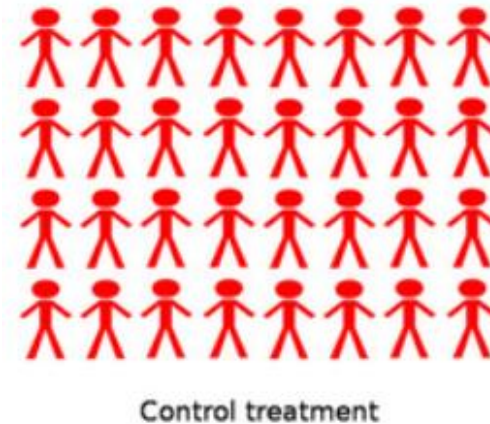
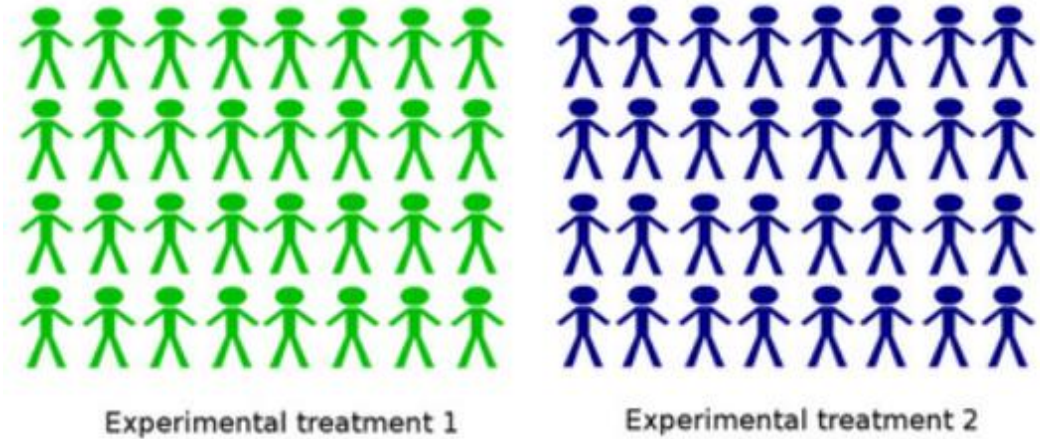
- Multiple Treatment Groups

- Multiple treatment groups with a control

- Treatment 1 : template 형태가 A인 e-mail 송부
    - Treatment 2 : template 형태가 B인 e-mail 송부
    - Control : not sending e-mail

- Multiple treatment groups without a control

- Treatment 1 : module 형태가 A인 web-page
    - Treatment 2 : module 형태가 B인 web-page
    - Treatment 3 : module 형태가 C인 web-page
- Web-page 방문하는 모두에게 3가지 중 하나가 보여지므로, control group이 없다.



# Multiple Treatment Groups

## • Meta-learners for Multiple Treatment Groups

### 1) Extending X-learner for Multiple Treatment : m개의 treatment group과 control group이 있다고 가정

1. 각 group 별, response model을 적합 한다. (base learners for the first stage)

$$\mu_{t_j}(x) = E[Y^{obs} | X = x, T = t_j], \quad \text{where } t_j \in \{t_0, t_1, t_2, \dots, t_m\}$$

2. Base learner를 이용해 각 객체의 treatment effect를 추정한다. (imputed treatment effects)

$$\widetilde{D}_i^{t_j} = Y_i - \widehat{\mu}_{t_0}(X_i), \quad \widetilde{D}_i^{t_0} = \widehat{\mu}_{t_j}(X_i) - Y_i$$

2-1.  $\tau_{t_j}(x) = E[\widetilde{D}^{t_j} | X = x]$ 을 추정하기 위해 j번째 treatment group에 대해  $\widetilde{D}^{t_j}$ 을 반응 변수로,  $X$ 를 설명 변수로 설정하여 예측 모델을 적합 한다.

마찬가지로,  $\tau_0(x) = E[\widetilde{D}^0 | X = x]$ 을 추정하기 위해 control group에 대해  $\widetilde{D}^0$ 을 반응 변수로,  $X$ 를 설명 변수로 설정하여 예측 모델을 적합 한다.  
(base learners for the second stage)

2-2. 각 m개의 treatment group에 대해, 성향 점수를 추정한다 :  $e_{t_j} = P(T = t_j | X = x)$

3. 2-1 기반의 base-learner 이용해 CATE 추정량을 다음과 같이 정의한다.

$$CATE = \widehat{\tau}^{t_j}(x) = \frac{\widehat{e}_{t_j}(x)}{\widehat{e}_{t_j}(x) + \widehat{e}_{t_0}(x)} \widehat{\tau}_{t_0}(x) + \frac{\widehat{e}_{t_0}(x)}{\widehat{e}_{t_j}(x) + \widehat{e}_{t_0}(x)} \widehat{\tau}_{t_j}(x)$$

3-1. 개인에게 가장 적합한 treatment를 추정하기 위해, 다음의  $\tau^{t_j}(X_i)$ 를 계산하고, 가장 값이 큰 treatment group에 배정하면 된다.

$$\widehat{\tau}^{t_j}(X_i) = \frac{\widehat{e}_{t_j}^{(-i)}(X_i)}{\widehat{e}_{t_j}^{(-i)}(X_i) + \widehat{e}_{t_0}^{(-i)}(X_i)} \widehat{\tau}_{t_0}^{(-i)}(X_i) + \frac{\widehat{e}_{t_0}^{(-i)}(X_i)}{\widehat{e}_{t_j}^{(-i)}(X_i) + \widehat{e}_{t_0}^{(-i)}(X_i)} \widehat{\tau}_{t_j}^{(-i)}(X_i)$$

# Multiple Treatment Groups

## • Meta-learners for Multiple Treatment Groups

2) Extending R-learner for Multiple Treatment : m개의 treatment group과 control group이 있다고 가정

1. 각 group 별, response model 및 성향 점수 추정 model을 적합 한다.

$$e_{t_j} = P(T = t_j | X = x)$$

$$\mu_{t_j}(x) = E[Y^{obs} | X = x, T \in \{t_0, t_j\}], \quad \text{where } t_j \in \{t_1, t_2, \dots, t_m\}$$

2. 이전과 동일하게, m개의 treatment group에 대해 다음과 같은 경험적 손실 함수를 설정한다.

$$\tilde{\tau}(\cdot) = \operatorname{argmin} \left( \frac{1}{n} \sum_{i=1}^n \left[ \{Y_i - \mu_{t_j}(X_i)\} - \{T_i - e_{t_j}(X_i)\} \tau_{t_j}(X_i) \right]^2 + \Lambda_n\{\tau(\cdot)\} \right) = \operatorname{argmin}[L_n\{\tau(\cdot)\} + \Lambda_n\{\tau(\cdot)\}]$$

$$\hat{\tau}(\cdot) = \operatorname{argmin}[\widehat{L}_n\{\tau(\cdot)\} + \Lambda_n\{\tau(\cdot)\}]$$

3. 개인에게 가장 적합한 treatment를 할당하고자 할 때는, 다음의 손실 함수를 최소화하는  $\tau^{t_j}$ 를 계산하고, 가장 값이 큰 treatment group에 배정하면 된다.

$$\widehat{L}_n\{\tau(\cdot)\} = \frac{1}{n} \sum_{i=1}^n \left[ \{Y_i - \widehat{\mu}_{t_j}^{(-i)}(X_i)\} - \{T_i - \widehat{e}_{t_j}^{(-i)}(X_i)\} \tau_{t_j}(X_i) \right]^2$$

# Multiple Treatment Groups with Different Costs

- Use Cases with Different Costs

- 그동안의 Uplifting model은 각 treatment 별 드는 비용이 동일하다고 가정함

- 두 가지 treatment cost structure가 있음


- Impression cost : 모든 treated unit에 들어가는 동일한 비용  
(ex. Paid channels)

- Triggered cost : Triggered cost for each converted user  
(ex. 구매 금액 별 할인률, 구매하지 않는 고객에게는 비용이 들어가지 않음)

- Net Value(순 가치)

= Conversion rate – Treatment cost

- 앞서 소개한 Meta-learner 들은 conversion rate를 optimizing 하는데 집중하였다면, costs를 고려할 때는 순 가치(net value)를 최대화하는데 집중한다.



# Multiple Treatment Groups with Different Costs

- Net Value Optimization for Multiple Treatment Groups with Different Costs

- m개의 treatment group과 control group이 있다고 가정

- Notation 정의

1)  $v$  : Conversion rate로, 모든 unit에 동일하고 사전 지식에 의해 알려진 상수라 가정한다.

2)  $C_{t_j}$  for  $j \in \{0, 1, \dots, m\}$  : 각 treatment 별 드는 impression cost(고정 비용)

3)  $S_{t_j}$  for  $j \in \{0, 1, \dots, m\}$  : 각 treatment 별 드는 triggered cost(변동 비용)

- Expected Net Value for user  $i$  under treatment  $t_j$

$$E[(v - s_{t_j})Y_{t_j} - c_{t_j} | X = x]$$

- Net Value CATE under treatment  $t_j$

$$\tau^{t_j}(x, v, s_{t_j}, c_{t_j}) = E[(v - s_{t_j})Y_{t_j} - (v - s_{t_0})Y_{t_0} - (c_{t_j} - c_{t_0}) | X = x]$$



# Multiple Treatment Groups with Different Costs

## • Net Value Optimization for Multiple Treatment Groups with Different Costs

### 1) Extending X-learner for Net Value CATE

- 각 group 별 response model, propensity score 추정 model, CATE 추정 방정식 모두 Multiple treatment 상황 때 사용한 것과 동일하다.

$$\mu_{t_j}(x) = E[Y^{obs} \mid X = x, T = t_j], \quad \text{where } t_j \in \{t_0, t_1, t_2, \dots, t_m\} \quad e_{t_j} = P(T = t_j \mid X = x)$$

$$CATE = \widehat{\tau}^{t_j}(x) = \frac{\widehat{e}_{t_j}(x)}{\widehat{e}_{t_j}(x) + \widehat{e}_{t_0}(x)} \widehat{\tau}_{t_0}(x) + \frac{\widehat{e}_{t_0}(x)}{\widehat{e}_{t_j}(x) + \widehat{e}_{t_0}(x)} \widehat{\tau}_{t_j}(x)$$

- 2번째 단계(imputed treatment effects) 때 사용하는 공식에만 변화를 준다.

$$\widehat{D}_i^{t_j, t_0}(x_i^{t_j}, Y_i^{t_j}) = (v - s_{t_j}) Y_i - (v - s_{t_0}) \mu_{t_0}(x_i^{t_j}) - (c_{t_j} - c_{t_0})$$

$$\widehat{D}_i^{t_j, t_0}(x_i^{t_0}, Y_i^{t_0}) = (v - s_{t_j}) \mu_{t_j}(x_i^{t_0}) - (v - s_{t_0}) Y_i^{t_0} - (c_{t_j} - c_{t_0})$$

### 2) Extending R-learner for Net Value CATE

- 각 group 별 response model, propensity score 추정 model 모두 Multiple treatment 상황 때 사용한 것과 동일하다.

$$\mu_{t_j}(x) = E[Y^{obs} \mid X = x, T \in \{t_0, t_j\}], \quad \text{where } t_j \in \{t_1, t_2, \dots, t_m\} \quad e_{t_j} = P(T = t_j \mid X = x)$$

- 최소화 시키고자 하는 손실 함수의 형태만 달라진다.

$$\tilde{\tau}(\cdot) = \operatorname{argmin} \left( \frac{1}{n} \sum_{i=1}^n \left[ \left\{ (v - s_i) Y_i - (v - \bar{s}) \mu_{t_j}(X_i) - (c_i - \bar{c}) \right\} - \left\{ T_i - e_{t_j}(X_i) \right\} \tau_{t_j}(X_i) \right]^2 + \Lambda_n\{\tau(\cdot)\} \right) = \operatorname{argmin} [L_n\{\tau(\cdot)\} + \Lambda_n\{\tau(\cdot)\}]$$


# Example of Multiple Treatment Groups with Different Costs

Want to know) 예산이 주어졌을 때, Net value를 최대화시키는 맞춤형 promotion은 무엇일까?

- Promotion campaign 실험으로부터 수집된 data 이용
    - Control group : receive no promotion
    - Treatment group 1 : receive A promotion
    - Treatment group 2 : receive B promotion
  - Data 내 cost structure
    - impression cost : communication channel과 연관된 비용
      - 이때, communication channel에 드는 direct cost는 적으나, hidden cost까지 고려해 산정하였다. (ex. 너무 많은 promotion 보내면, 사용자들이 구독 취소를 할 수 있음)
    - triggered cost : 사용자가 상품을 사용할 때 발생하는 promotion amount
    - Control group : 관련 비용 없음
    - Treatment group 1 : impression cost 0.01, triggered cost 0.2
    - Treatment group 2 : impression cost 0.01, triggered cost 0.3
- } 사업 기밀 상, 비용 re-scale 진행
- 개인 별, conversion rate는 1이라 가정
  - Data를 train set(600K)과 test set(800K)로 분리한 후, train set 이용해 다양한 Meta-learner 적합 후 test 이용해 성능 비교
    - base-learner 모두 random forest 사용
    - 사용한 공변량 수는 139개
    - tree 수는 50개로 설정

# Example of Multiple Treatment Groups with Different Costs

Want to know) 예산이 주어졌을 때, Net value를 최대화시키는 맞춤형 promotion은 무엇일까?



## • 주목할 만한 부분

- 제안한 model이 incremental conversion 가능성과 관련 비용 사이의 trade-off를 고려하므로 net value optimization group에서 평균 conversion rate더 높을 거란 보장이 없다는 것이다.

Ex) control group의 평균 conversion rate를 0.53%, treatment 1 group의 평균 conversion rate를 1.39 %, treatment 2 group의 평균 conversion rate를 2.18 %라 하자.

→ Treatment 1 group의 평균 conversion rate가 control group보다 더 높지만, 관련 비용을 제외한 순 가치(net value)는 control group이 더 높다.

→ Net value optimization algorithm은 Promotion을 통한 conversion rate의 증분이 알려진 비용보다 낮을 때, expected net value는 증가시키면서, average conversion rate는 낮추는 기능을 가지고 있다.

- 위 Figure를 보면, 제안한 Net-value optimization meta-learner의 성능이 가장 나음을 알 수 있다.

**감사합니다**  
**Q&A**